

Análise de Risco de Crédito

Default of Credit Card Clients — UCI Machine Learning Repository

Trabalho Final Prático — Python & Pandas
Disciplina: Novas Tecnologias / Ciência de Dados
Prof. William Malvezzi

Integrantes do Grupo 03	Pergunta sob responsabilidade
Ana Beatriz Gonçalves Bastos	P1 — Score de risco · P5 — Outliers IQR (BILL_AMT)
Matheus Martins Rios	P2 — Taxa de inadimplência por perfil
Gustavo Xavier	P3 — Comportamento de pagamento da fatura
Yuri	P4 — Matriz de correlação
Matheus Henrique	P6 — Segmentação de perfis (clustering)
Otávio Henrique do N. Cunha	P7 — Ranking de limite · P8 — Piora progressiva

Base: 30.000 clientes de cartão de crédito (Taiwan, 2005) · 25 variáveis originais

Sumário

Seção	Título
01	Resumo Executivo
02	Objetivo e Proposta
03	Descrição da Base de Dados
04	Dicionário de Dados
05	Metodologia e Ambiente
06	Limpeza e Tratamento dos Dados

07	Transformação e Criação de Variáveis
08	Análise Exploratória — As 8 Perguntas
09	Análise de Correlação
10	Indicadores Sintéticos
11	Gargalos Técnicos e Resolução de Erros
12	Conclusões e Limitações

01 Resumo Executivo

Este relatório apresenta uma análise completa de risco de crédito sobre a base Default of Credit Card Clients, contendo 30.000 clientes de cartão de crédito de Taiwan em 2005. O objetivo central é identificar quais características financeiras e comportamentais estão associadas à inadimplência no mês seguinte.

A taxa geral de inadimplência observada foi de **22,12%** (6.636 de 30.000 clientes). A análise revelou que o **histórico recente de pagamento** é o fator mais determinante: a variável de atraso mais recente (PAY_0) apresentou a maior correlação positiva com o default ($r = 0,32$), e clientes com seis meses consecutivos de atraso atingiram taxa de inadimplência de 70,32%, contra 11,71% dos que nunca atrasaram.

Variáveis demográficas (sexo, escolaridade, estado civil) mostraram associação mais fraca, porém perceptível. O limite de crédito apresentou correlação negativa ($r = -0,15$), indicando que clientes com maior limite — perfil de melhor avaliação pelo banco — inadimplam menos.

02 · Objetivo e Proposta

Aplicar Python e a biblioteca Pandas para realizar uma análise completa de uma base de dados real, desde a leitura até a construção de conclusões fundamentadas, passando por limpeza, transformação, exploração estatística e visualização.

O grupo escolheu o Tema 03 — Finanças e Risco de Crédito. Foram definidas oito perguntas de análise, cada uma sob responsabilidade de um integrante, conforme detalhado na capa. As perguntas cobrem perfil demográfico, comportamento de pagamento, score de risco, correlações, detecção de outliers e padrões temporais de inadimplência.

03 · Descrição da Base de Dados

A base foi obtida do UCI Machine Learning Repository (dataset 350), carregada diretamente via biblioteca ucimlrepo. Possui 30.000 registros e 25 colunas originais, todas numéricas (int64), sem valores ausentes na origem.

Característica	Valor	Exigência
Registros	30.000	Mín. 500 ✓
Colunas originais	25	Mín. 10 ✓
Variáveis numéricas	20+	Mín. 4 ✓
Variáveis categóricas	4 (SEX, EDUCATION, MARRIAGE, PAY_*)	Mín. 3 ✓
Variável-alvo	default.payment.next.month	—

Observação importante: as colunas EDUCATION e MARRIAGE contêm valores não documentados (0, 5 e 6), tratados como categoria “Não Informado”. Os valores de fatura (BILL_AMT) podem ser negativos, representando crédito a favor do cliente.

04 Dicionário de Dados

Tradução das colunas originais (X1–X23, Y) para nomes legíveis e seu papel na análise:

Coluna	Significado	Papel
LIMIT_BAL	Limite de crédito concedido (NT\$)	Preditora
SEX	Sexo (1=M, 2=F)	Preditora
EDUCATION	Escolaridade (1=Pós a 4=Outros)	Preditora
MARRIAGE	Estado civil (1=Casado, 2=Solteiro)	Preditora
AGE	Idade em anos	Preditora
PAY_0 ... PAY_6	Status de atraso (set/2005 a abr/2005)	Preditora
BILL_AMT1 ... 6	Valor das faturas dos 6 meses	Preditora
PAY_AMT1 ... 6	Valor pago em cada mês	Preditora
DEFAULT	Inadimplência no mês seguinte (1/0)	Alvo
ID	Identificador do cliente	Removida

Escala PAY: -2 = sem consumo, -1 = pagou em dia, 0 = crédito rotativo (pagamento mínimo), 1 a 9 = meses de atraso. Essa escala foi fundamental para o score de risco e a contagem de atrasos.

05 · Metodologia e Ambiente

O trabalho foi desenvolvido em Google Colab (Python 3.12), com as seguintes bibliotecas:

Biblioteca	Versão	Uso
pandas	2.2.2	Manipulação e análise de dados tabulares
numpy	2.0.2	Operações matemáticas e lógica condicional
matplotlib	3.x	Geração de gráficos
seaborn	0.13.x	Gráficos estatísticos (heatmap)
ucimlrepo	0.0.7	Carregamento direto da base UCI

Decisão metodológica: a classificação de clientes em categorias de risco foi feita por critérios estatísticos explícitos (comparação de valores, faixas com `pd.cut`, regras condicionais com `np.select`), de forma auditável e interpretável. A Pergunta 6 utiliza adicionalmente o algoritmo KMeans — ver Seção 11.

06 Limpeza e Tratamento dos Dados

Embora a base não apresente valores nulos na origem, foram aplicadas as seguintes etapas de tratamento para garantir consistência analítica:

- **Renomeação das colunas** de X1–X23/Y para nomes descritivos (LIMIT_BAL, PAY_0, DEFAULT, etc.).
- **Remoção da coluna ID**, apenas identificador sequencial sem valor analítico.
- **Tratamento de categorias inválidas**: valores 0, 5 e 6 em EDUCATION e 0 em MARRIAGE agrupados em “Não Informado” com map().
- **Verificação de duplicatas com drop_duplicates()**: não há linhas com todas as colunas idênticas (incluindo o ID, que é único por definição). No entanto, ao comparar apenas o perfil financeiro completo (as 24 variáveis, exceto ID), foram encontrados 35 clientes com perfil idêntico a outro cliente da base. Optou-se por manter esses registros: cada linha representa um cliente real, identificado por ID próprio, e a coincidência de perfil é estatisticamente esperada em uma base de 30.000 linhas com variáveis discretas de baixa cardinalidade (limite de crédito, idade, sexo etc. assumem poucos valores possíveis). Remover esses registros reduziria artificialmente o tamanho da amostra sem corrigir nenhum erro real de coleta.
- **Padronização de texto com str.strip() e str.upper()**: aplicada às colunas categóricas (SEX, EDUCATION, MARRIAGE) após a conversão dos códigos numéricos originais em rótulos textuais, garantindo que valores como "Casado" e "casado " nunca sejam tratados como categorias distintas em agrupamentos futuros.
- **Construção de um dicionário de dados técnico** (tipo, quantidade e percentual de nulos, valores únicos e exemplo de cada coluna), que confirmou de forma sistemática a ausência de valores ausentes em todas as 25 colunas originais.

Estratégia para nulos (caso surdissem após transformações): mediana para variáveis numéricas e moda para categóricas, preservando a distribuição original.

07 · Transformação e Criação de Variáveis

Foram criadas variáveis derivadas para enriquecer a análise:

Variável criada	Como foi construída	Técnica
QTD_ATRASOS	Contagem de meses com atraso > 0	(df[pay]>0).sum()
PROP_PAGAMENTO	Total pago ÷ total faturado (0–1)	np.where + np.clip
SCORE_RISCO_NUM	10 pts/atraso + 40 pts por falta de pgto	Aritmética
CATEGORIA_RISCO	Faixas: Baixo / Médio / Alto	pd.cut
COMPORTAMENTO_PAG	Pagou Total / Parcial / Não Pagou	np.select
faixa_etaria	Faixas: <18, 18-25, 26-35, 36-50, 50+	pd.cut

Exemplo do score de risco (P1): um cliente que faturou NT\$10.000, pagou NT\$6.000 e acumulou 3 atrasos recebe $\text{score} = 3 \times 10 + (1 - 0,6) \times 40 = 46$ pontos, classificado como Risco Médio.

08 Análise Exploratória — As 8 Perguntas

Pergunta 1 — Score de risco (Ana Beatriz)

Foi construído um score numérico combinando quantidade de atrasos e proporção de pagamento, depois categorizado em três faixas (Baixo, Médio, Alto) com `pd.cut`. O score sintetiza em uma única métrica o comportamento financeiro de cada cliente.

Pergunta 2 — Taxa de inadimplência por perfil (Matheus Rios)

A taxa geral é de **22,12%**. Por sexo, homens inadimplam mais (24,17%) que mulheres (20,78%). Por escolaridade, Ensino Médio concentra a maior taxa (25,16%), e por estado civil, a categoria Outros lidera (26,01%).

Aprofundamento — Tabela Cruzada e Agrupamento Multinível. Complementando a tabela pivô de Sexo × Escolaridade, foi construída uma tabela cruzada (`crosstab`) de Sexo × Estado Civil, que mostrou que homens na categoria "Outros" (estado civil) apresentam a maior taxa de inadimplência entre os subgrupos de sexo, próxima de 30%.

Para identificar combinações específicas de maior risco, foi feito um agrupamento simultâneo por três variáveis categóricas (Sexo × Escolaridade × Estado Civil), com `.agg()` calculando total de clientes, taxa de inadimplência e limite de crédito médio por grupo (filtrando combinações com menos de 50 clientes, para evitar taxas instáveis calculadas sobre amostras pequenas). O grupo de maior risco identificado foi homens com ensino superior e estado civil "Outros" (30,16% de inadimplência, 63 clientes), seguido por homens com Ensino Médio e estado civil "Casado" (28,91%, 1.048 clientes). Essa granularidade não é visível quando cada variável é analisada isoladamente, reforçando o valor de cruzamentos multivariados na identificação de perfis de risco.




Figura 1 — Taxa de inadimplência e distribuição absoluta por sexo.




Figura 2 — Taxa de inadimplência e situação por escolaridade.




Figura 3 — Taxa de inadimplência e distribuição dos inadimplentes por estado civil.

Estado civil	Total	Inadimplentes	Taxa
Casado	13.659	3.206	23,47%
Solteiro	15.964	3.341	20,93%
Outros	323	84	26,01%
Não Informado	54	5	9,26%

Tabela — Inadimplência por estado civil.

Pergunta 3 — Comportamento de pagamento da fatura (Gustavo)

Os clientes foram classificados em três grupos conforme o pagamento de setembro/2005: **Pagou Total** (quitou integralmente), **Pagou Parcial** (rotativo/mínimo) e **Não Pagou**. A distribuição: 73,7% pagou parcial, 14,4% pagou total e 12,0% não pagou.




Figura 4 — Taxa de inadimplência por comportamento de pagamento.




Figura 5 — Distribuição do valor pago por grupo (box plot).

Interpretação: os números confirmam a hipótese de forma clara. Clientes que quitaram a fatura integralmente apresentam taxa de default de **15,5%**; os que pagaram parcialmente, **20,0%**; e os que não realizaram nenhum pagamento, **39,8%** — mais que o dobro do primeiro grupo. O pagamento integral no mês anterior é o sinal mais claro de saúde financeira. **Limitação:** o dataset não distingue pagamento mínimo obrigatório de parcelamento voluntário — ambos aparecem como “Pagou Parcial”.

Pergunta 4 — Matriz de correlação (Yuri)

Detalhada na Seção 09. A variável PAY_0 destacou-se como a mais correlacionada com o default.

Pergunta 5 — Outliers em BILL_AMT com IQR (Ana)

Aplicou-se o método do Intervalo Interquartil (IQR) sobre BILL_AMT1 para identificar faturas extremas (limites em $Q1 - 1,5 \times IQR$ e $Q3 + 1,5 \times IQR$). Os outliers superiores representam clientes com faturas muito acima da média, geralmente associados a limites de crédito elevados. **Pendência:** o requisito exige IQR em pelo menos 2 colunas — recomenda-se estender a análise a BILL_AMT2.

A análise foi estendida a uma segunda coluna, BILL_AMT3 (extrato de três meses antes), atendendo ao requisito de aplicar o método em pelo menos duas variáveis numéricas. A proporção de outliers identificada em BILL_AMT3 foi muito próxima da observada em BILL_AMT1, e o box plot comparativo entre as duas colunas mostrou distribuições praticamente equivalentes em formato e assimetria. Isso indica que o padrão de poucos clientes com faturas muito elevadas não é um evento pontual de um mês específico, mas uma característica estrutural do comportamento de consumo dessa base de clientes — reforçando a interpretação de que esses valores extremos são, em sua maioria, legítimos (clientes de maior poder aquisitivo), e não erros de lançamento.

Pergunta 6 — Segmentação de perfis / clustering (Matheus Henrique)

Utilizou-se o algoritmo KMeans (4 clusters) sobre variáveis padronizadas (limite, idade, médias de fatura e pagamento, oscilações, utilização do limite e meses sem pagamento). Os quatro segmentos foram interpretados e nomeados:

Perfil	Clientes	Característica predominante
A — Adimplente Ativo	13.790	Pagamentos consistentes, baixa utilização
B — Adimplente Passivo	6.141	Faturas e pagamentos elevados, idade mais alta

C — Risco Moderado	7.479	Comportamento intermediário
D — Alto Risco	2.590	Meses com atraso acima da média




Figura 6 — Quantidade de clientes por perfil identificado.




Figura 7 — Perfil médio padronizado de cada segmento (mapa de calor).

Observação metodológica: esta análise usa aprendizado não supervisionado (KMeans), diferente das demais perguntas. A escolha foi discutida pelo grupo — ver Seção 11.

Pergunta 7 — Ranking de limite e poder preditivo dos atrasos (Otávio)

Clientes com limites extremos (acima de NT\$525.000, identificados por IQR — 167 clientes) apresentam taxa de inadimplência de apenas 11,38%, contra 22,18% dos clientes de limite normal. Isso indica que limites altos são concedidos a perfis de baixo risco. A contagem de atrasos (QTD_ATRASOS) confirmou-se forte preditor: clientes sem atrasos têm taxa de 11,71%, subindo progressivamente até 70,32% para quem acumulou seis meses de atraso.

Estatística Descritiva Aprofundada

Além das variáveis derivadas, foi realizada uma leitura estatística aprofundada de duas variáveis numéricas centrais — LIMIT_BAL e AGE — comparando média, mediana, desvio padrão e coeficiente de assimetria (skewness). LIMIT_BAL apresentou média (NT\$ 167.484) superior à mediana (NT\$ 140.000) e assimetria positiva de 0,99, evidenciando uma distribuição com cauda longa à direita, puxada por um grupo menor de clientes com limites de crédito muito elevados. AGE apresentou assimetria mais suave (0,73), com média (35,5 anos) e mediana (34 anos) mais próximas entre si, indicando uma distribuição etária mais regular, concentrada majoritariamente entre 25 e 40 anos. Esse padrão se repete na Seção 08 (Pergunta 5): variáveis monetárias tendem a ser fortemente assimétricas em bases de crédito, enquanto variáveis demográficas tendem a uma distribuição mais simétrica.

Pergunta 8 — Piora progressiva por idade (Otávio)

A hipótese de piora progressiva foi confirmada: clientes que inadimpliram não pararam de pagar subitamente — acumularam atrasos crescentes ao longo do semestre. Em abril, 16% a 26% dos futuros inadimplentes já estavam em atraso; em setembro, 48% a 59%. O grupo 50+ apresentou o pico mais acentuado (58,90% em setembro).




Figura 8 — Evolução do atraso ao longo dos meses, por faixa etária.

09 · Análise de Correlação

A matriz de correlação entre as variáveis numéricas foi visualizada como mapa de calor. A única variável com $|r| > 0,30$ em relação ao default foi PAY_0.




Figura 9 — Mapa de calor das correlações entre todas as variáveis (X1–X23, Y).




Figura 10 — Top 10 variáveis mais correlacionadas com o default (Y).

Interpretação das três correlações mais relevantes:

- **PAY_0 ($r = 0,32$, positiva):** quanto maior o atraso recente, maior a probabilidade de inadimplência. É o preditor mais forte.
- **PAY_2 a PAY_6 (positivas, decrescentes):** o histórico reforça o risco, mas perde força conforme o mês fica mais distante.
- **LIMIT_BAL ($r = -0,15$, negativa):** clientes com limite maior tendem a inadimplir menos.

Correlação não implica causalidade: a associação entre atraso e default não prova que o atraso cause a inadimplência. Fatores econômicos e pessoais podem influenciar ambos simultaneamente.

10 · Indicadores Sintéticos

Indicador	Valor
Taxa geral de inadimplência	22,12%
Total de clientes	30.000
Total de inadimplentes	6.636
Sexo de maior risco	Masculino (24,17%)
Escolaridade de maior risco	Ensino Médio (25,16%)
Estado civil de maior risco	Outros (26,01%)
Amplitude máxima entre grupos	19,47 pp

Os indicadores sintetizam os principais achados e servem de referência rápida para a tomada de decisão sobre concessão e monitoramento de crédito.

11 · Gargalos Técnicos e Resolução de Erros

Durante o desenvolvimento colaborativo do notebook surgiram erros de execução cuja causa principal foi o **recarregamento repetido e inconsistente da variável df** por diferentes integrantes. Esta seção documenta cada gargalo e sua resolução.

Gargalo 1 — **KeyError: 'DEFAULT'**

Onde: Pergunta 3 (Gustavo). **Causa:** a célula da Pergunta 2 nomeou a coluna-alvo como `default_payment`, enquanto o código da Pergunta 3 procurava `DEFAULT`. Como o `df` ativo era o da Pergunta 2, a coluna não existia com o nome esperado.

Resolução: padronizar o nome da coluna-alvo como `DEFAULT` no setup único, ou ajustar a referência no código da Pergunta 3. A causa raiz é a ausência de uma fonte única de verdade para o `df`.

Gargalo 2 — KeyError: 'BILL_AMT1'

Onde: Pergunta 3, após execução da Pergunta 6. **Causa:** a Pergunta 6 redefiniu `df = base.data.features.copy()`, revertendo as colunas para os nomes originais X1–X23. Assim, `BILL_AMT1` deixou de existir (voltou a ser `X12`).

Resolução: nenhum integrante deve recarregar o `df` dentro da própria célula. O grupo adotou um **SETUP ÚNICO** no topo do notebook que carrega e renomeia uma vez; cada pergunta trabalha em cópias locais (`df_g3`, `df_ana`, etc.) com `.copy()`, preservando o `df` principal.

Gargalo 3 — KeyError: 'LIMIT_BAL'

Onde: Pergunta 7 (Otávio). **Causa:** idêntica ao Gargalo 2 — o `df` foi resetado sem renomeação por uma célula anterior, e o código de Otávio dependia dos nomes legíveis.

Resolução: mesma do Gargalo 2. Com o setup único garantido, todas as colunas legíveis ficam disponíveis para todas as perguntas, independentemente da ordem de execução.

Gargalo 4 — Inconsistência de mapeamento PAY

Causa: diferentes integrantes mapearam as colunas de atraso de formas distintas — alguns usaram `PAY_1` (que não existe no dataset original; a sequência é `PAY_0`, `PAY_2`, `PAY_3`...). Isso gerou colunas ausentes em alguns agrupamentos.

Resolução: padronizar a lista oficial de colunas de atraso como `['PAY_0', 'PAY_2', 'PAY_3', 'PAY_4', 'PAY_5', 'PAY_6']` no setup único, usada por todos.

Recomendação de organização do notebook

- Uma única célula de setup (carregamento + renomeação + tratamento) logo após o Passo 1.
- Cada pergunta trabalha em cópia local com `.copy()`; ninguém sobrescreve o `df` principal.
- Validar com Runtime → Run all antes da entrega.
- Cada bloco de código precedido de Markdown explicativo e seguido de interpretação.

12 · Conclusões e Limitações

O que os dados revelaram:

- O comportamento de pagamento recente é o preditor dominante de inadimplência — muito mais que variáveis demográficas.
- A inadimplência é um processo progressivo: clientes que dão default acumulam atrasos por meses antes do evento.
- Limite de crédito alto está associado a menor risco, refletindo a qualidade da avaliação prévia do banco.

O que surpreendeu:

A força da relação entre quantidade de atrasos e default (de 11,71% para 70,32%) é mais acentuada do que o esperado, sugerindo que um simples contador de atrasos já seria um sistema de alerta precoce eficaz.

Limitações:

- Dados de um único país (Taiwan) e período curto (2005) — baixa generalização.
- A base é desbalanceada (22% de default), exigindo cautela ao interpretar percentuais.
- Não é possível distinguir pagamento mínimo de parcelamento voluntário.
- Análise observacional — não estabelece causalidade.

Referências: UCI Machine Learning Repository (archive.ics.uci.edu) · McKinney, W. Python for Data Analysis, 3ª ed., O'Reilly, 2022 · Documentação do Pandas (pandas.pydata.org/docs).